# LAPORAN TUGAS BESAR 2 IF2123

# Aljabar Linier dan Geometri

# Aplikasi Dot Product pada Sistem Temu-balik Informasi



# DISUSUN OLEH KELOMPOK 53

Muhammad Tito Prakasa 13519007

Mohammad Sheva Almeyda Sofjan 13519018

Aditya Bimawan 13519064

TEKNIK INFORMATIKA
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
2020/2021

#### **BABI**

### **DESKRIPSI MASALAH**

Membuat sebuah program berupa *website* sederhana yang mampu menyelesaikan berbagai permasalahan yang berkaitan dengan pembelajaran pada mata kuliah Aljabar Linier dan Geometri dengan spesifikasi sebagai berikut :

- 1. Program mampu menerima search query berupa kata dasar maupun berimbuhan.
- 2. Program mampu menerima dokumen (*upload* maupun scraping dari situs web lain), minimal terdapat 15 dokumen berbeda.
- 3. Program mampu menampilkan tabel kemunculan *term* pada *query* dan dokumen.
- 4. Program mampu mengalkulasikan nilai similaritas (*cosine similarity*) antara *query* dengan dokumen , lalu mengurutkan hasil pencarian berdasarkan nilai similaritas.
- 5. Hasil pencarian yang terurut berdasarkan similaritas tertinggi dari hasil teratas hingga hasil terbawah berupa judul dokumen dan kalimat pertama dari dokumen tersebut. Menampilkan juga nilai similaritas tiap dokumen.

#### **BAB II**

#### TEORI SINGKAT

#### 2.1 Dot Product dan Norma Suatu Vektor

Misalkan terdapat suatu vektor tidak nol u dan v di dalam ruang vektor  $R^n$  dengan komponen u =  $(u_1, u_2, u_3, ...., u_n)$  dan komponen v =  $(v_1, v_2, v_3, ...., v_n)$  maka dot product (perkalian titik atau perkalian skalar) dari u dan v (ditulis  $u \cdot v$ ) adalah

$$u \cdot v = u_1 v_1 + u_2 v_2 + u_3 v_3 + \dots + u_n v_n$$

dan norma Euclidean (panjang) vektor u adalah

$$||u|| = \sqrt{(u1)^2 + (u2)^2 + (u3)^2 + \dots + (un)^2}$$

## 2.2 Pemodelan Vektor dalam Information Retrieval (IR) System

Information Retrieval System atau Sistem Temu Balik Informasi adalah sistem pencarian informasi yang relevan terhadap kebutuhan pengguna (query) dari kumpulan informasi (dokumen) secara otomatis.Dalam kasus ini akan digunakan dokumen berbasis teks sebagai informasi.

Misalkan terdapat n kata berbeda sebagai suatu *term* atau kamus kata dalam suatu dokumen maupun query. Term / kata tersebut akan membentuk vektor u dalam ruang  $R^n$  dengan komponen u =  $(u_1, u_2, u_3, ..., u_n)$ , dengan  $u_i$  menyatakan bobot suatu kata di dalam dokumen atau query.

## 2.3 Term Frequency (TF)

*Term Frequency* merupakan frekuensi kemunculan suatu *term* (kata) dalam suatu dokumen atau query. *Term Frequency* dari suatu *term t* dalam dokumen d adalah

$$tf_{t,d} = log_{10}(count(t,d) + 1)$$

, dengan count(t,d) menyatakan banyaknya kemunculan term t dalam dokumen d.

### 2.4 Inverse Document Frequency (IDF)

Inverse Document Frequency menyatakan rarity atau kelangkaan suatu term dalam semua dokumen, semakin langka suatu term maka semakin besar nilai IDF dari term tersebut. IDF dari suatu term t dalam himpunan/ set dokumen D adalah

$$idf(t,D) = \log\left(\frac{N}{df(t)+1}\right)$$

, dengan N menyatakan banyaknya dokumen dan df(t) menyatakan jumlah dokumen yang mengandung *term* t.

## 2.5 Term Frequency - Inverse Document Frequency (TF - IDF)

*Term Frequency - Inverse Document Frequency* menyatakan hasil perkalian antara nilai TF dan nilai IDF suatu *term* dalam sebuah dokumen dalam susunan/set dokumen. TF-IDF dari suatu *term t*, sebuah dokumen d, dan himpunan/set dokumen D adalah

$$tfidf(t, d, D) = tf(t, d) \cdot idf(t, D)$$

, dengan syarat d anggota D.

## 2.6 Cosine Similarity

Cosine Similarity merupakan salah satu metode untuk menentukan similaritas antara dua vektor . Semakin tinggi nilainya semakin tinggi similaritas dua vektor tersebut. Misalkan terdapat suatu vektor tidak nol u dan v di dalam ruang vektor  $R^n$  dengan komponen  $u = (u_1, u_2, u_3, ..., u_n)$  dan komponen  $v = (v_1, v_2, v_3, ..., v_n)$  maka nilai Cosine Similarity dua vektor tersebut adalah

$$sim(u, v) = cos\theta = \frac{u \cdot v}{\|u\| \|v\|}$$

, dengan  $\, heta\,$  menyatakan sudut yang dibentuk antara vektor u dan v.

# BAB III IMPLEMENTASI PROGRAM

# • File tfidf.py

Nama	Tipe data keluaran	Keterangan	
stem(string)	List	Digunakan untuk stemming input kata	
setkata(arrkalimat	set	Mereturn set berisi semua kata yang muncul	
wordcount(kalim at,setkata)	dictionary	Menghitung kemunculan tiap kata pada tiap dokumen/query	
wordcount_matx( arrkalimat)	List of dictionary	mengubah tiap array dalam arrkalimat menjadi dictionary dengan keytiap kata dan value jumlah kemunculannya (serupa dgn vektor)	
tf(wordcount_vec t)	Dictionary	output dict vector dengan nilai tiap kolom berupa nilai TF pada dokumen wordcount_vect	
tf_matx(wordcou nt_arr)	Matrix	output matrix dengan nilai tiap kolom berupa nilai TF dari kata tersebutpada dokumen masing-masing, dengan input matrix wordcount	
idfvect(wordcoun t_arr)	Dictionary	mereturn vector (dictionary dengan value float) dengan inputarray vektor wordcount	
tf_idf(tf, idf)	Dictionary	Mereturn dictionary berupa nilai tfidf suatu vektor	
cosine_sim(tfidf1 ,tfidf2)	Float	Mereturn nilai cosine similarity antara 2 dict tfidf	

# • File webscraper.py

Nama	Tipe Data Keluaran	Keterangan
isiKonten(link)	String	Fungsi berparameter suatu link dan akan mereturn isi konten dari link tersebut (artikel berita)

# • File mainjson.py

Nama	Tipe data keluaran	Keterangan
getsorted(query)	Dictionary	Mereturn dictionary yang berisi artikel/dokumen yang sudah disortir berdasarkan similaritas dengan query
similarity(wcount ,tiq,idfvect)	Float	Mereturn similaritas antara tiq dan tfidf dari tf(wcount) dan idfvect
tablemaker(query	Dataframe(pand as)	Mereturn tabel kemunculan term (sudah di sortir berdasarkan similaritas) berupa dataframe

# • File maintxt.py

Nama	Tipe data keluaran	Keterangan
getsortedtxt(quer y)	Dictionary	Mereturn dictionary yang berisi artikel/dokumen yang sudah disortir berdasarkan similaritas dengan query
get_localcorpus()	List of dictionary	Mereturn list of dictionary berupa corpus dari file .txt pada path ./txt/
get_localcontent( doc)	String	Mereplace newline (\n) pada hasil read file dengan spasi (' ')
tablemakertxt(qu ery)	Dataframe(pand as)	Mereturn tabel kemunculan term (sudah di sortir berdasarkan similaritas) berupa dataframe

# • File flasksite.py

Nama	Keterangan	
searchForm(form	Display search bar dan pilihan dibawahnya	
allowed_file(filen	Nantinya digunakan di upload() . Mereturn apakah file dapat	

ame)	diupload (dalam ekstensi .txt) atau tidak	
home()	Render home.html (homepage)	
search()	Render hasil search sesuai dengan pilihan	
txt(txt_name)	Mereturn file txt dari path (jika ada) dan pesan FileNotFoundError(jika tidak ada file .txt)	
about()	Render about.html	
upload()	Fitur upload file dengan extension yang diperbolehkan (.txt) pada path tertentu	
deltxt()	Menghapus semua file .txt pada path	

#### **BAB IV**

#### **EKSPERIMEN**

## 4.1 Webscraping

### 4.1.1 Percobaan 1 (Ekstrak Raw)

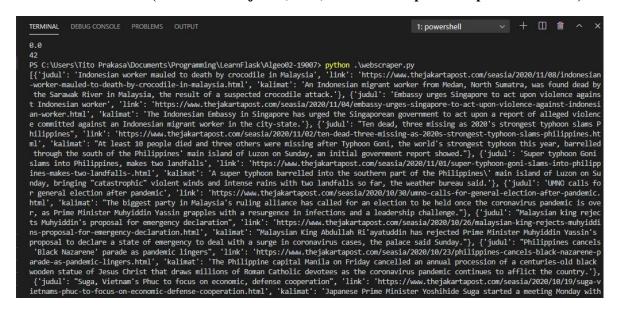
PS C:\Users\Tito Prakasa\Documents\Programming\LearnFlask> python .\webscraper.py

Dalam dunia kesehatan maupun pendidikan, ada pepatah kuno yang sudah tidak asing lagi di telinga masyarakat. Men sana in corpore sano, sebuah pepatah kuno yang diserap dari bahasa latin ini memiliki makna "jiwa yang sehat dalam tubuh yang sehat". Artinya, pikiran yang sehat dan ten ang akan menumbuhkan raga yang sehat pula.Penyakit muncul karena berbagai faktor. Faktor paling umum adalah karena makanan yang tak sehat dan pola hidup yang tidak beraturan. Namun tahukah anda bahwa pikiran yang tidak sehat juga akan menimbulkan berbagai macam penyakit?Ada banyak macam penyakit yang justru lebih parah apabila kita memikirkan hal-hal buruk kedepannya. Pikiran yang buruk akan menyebabkan stamina tubuh me ngalami penurunan. Kecemasan yang berlebihan tentunya sangat tidak baik bagi tubuh, apalagi bila sedang dalam proses pemulihan. Berpikir posi tif dan sehat akan membuat mood naik sehingga menambah stamina tubuh. Hasilnya, seseorang yang sedang melawan penyakitnya akan semakin semang at untuk sembuh dan penuh ambisi untuk bebas dari rasa sakit. Tahun 2020 menjadi tahun yang tidak mudah bagi dunia, terutama Indonesia. Mewabahnya Covid-19 hingga ditetapkan sebagai pandemi global membuat semua sektor kocar-kacir hingga membludaknya pasien di awal-awal masa pan demi. Seluruh tenaga kesehatan sebagai garda terdepan kewalahan menangani banyaknya pasien yang terus bertambah tiap harinya. Kurangnya tempa taha fasilitas kesehatan yang memadai membuat karantina selama 14 hari terasa mencekam dan membosankan. Pikiran-pikiran negatif juga pastiny a menghantui para pasien hingga membuat imunitas menurun dan keadaan menjadi drop. Seiring berjalannya waktu, berbagai kabar baik mulai meram aikan media. Pasien sembuh kian bertambah tiap harinya. Hal ini memicu pemikiran para pasien dan tenaga kesehatan bahwa mereka semua mampu me nghadapinya dengan baik. Sekali lagi, suasana yang positif, pikiran yang positif akan menimbulkan semangat-semangat baru bagi

# Mengambil test referensi dari website

https://www.kompasiana.com/qoniatul15454/5faca6ec633122418f314f22/opini-pepatah-kuno-untuk-hari-kesehatan-nasional gambar di atas merupakan contoh hasil kasar dari scraping suatu webpage berita.

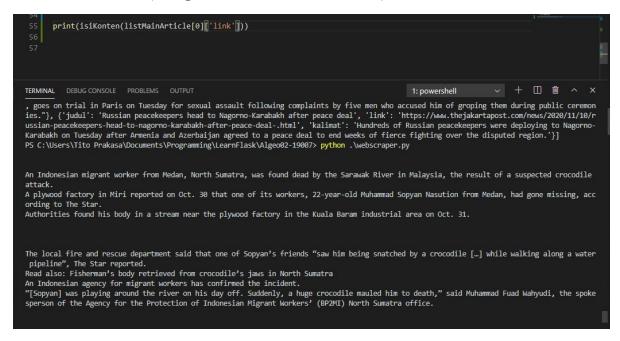
# 4.1.2 Percobaan 2 (Memisahkan judul, link, dan kalimat pertama pada dokumen)



Terjadi perubahan dari dokumen berbahasa indonesia ke berbahasa inggris karena library yang digunakan untuk men-stemming kata khusus untuk bahasa inggris. Pada

percobaan kali ini referensi website yang digunakan adalah <a href="https://www.thejakartapost.com/">https://www.thejakartapost.com/</a> dan agar penyimpanan ringkas, setiap dokumen disimpan dalam list of dict dengan index judul, link, dan kalimat.

# 4.1.3 Percobaan 3 (Mengambil isi dokumen dari link)



Dari list of dict di percobaan kedua, kami mengambil sample link pada elemen pertama (index ke-0) lalu dimasukkan pada fungsi isiKonten(link) dan mereturn string seperti di atas.

# 4.2 Vektorisasi dan Cosine Similarity

### 4.2.1 Percobaan Vektorisasi (query : Zara love to hate hate walk)

Dibawah ini adalah dokumen tes

Dibawah ini adalah dictionary vektor kemunculan term query pada query (atas) dan pada dokumen tes (bawah)

```
\Algeo\Algeo\2-19007'; & 'C:\Users\ASUS\AppData\Local\Programs\Python\Python\So\Python.exe' 'c:\Users\ASUS\\.vscode\extensions\ms-python.python-2020.11.358366026\pythonfiles\
Iib\python\debugpy\launcher' '51648' '--' 'c:\Users\ASUS\Desktop\Algeo\Algeo\2-19007\test.py'
('hate': 2, 'zana': 1, 'love': 1, 'walk': 1)
[('go': 1, 'didnt': 0, 'wall': 0, 'poop': 1, 'back': 1, 'later': 1, 'love': 0, 'surpris': 0, 'head': 0, 'your': 1, 'seem': 0, 'extrovert': 0, 'mind': 1, 'zana': 0, 'better'
: 2, 'turn': 0, 'wann': 0, 'sometim': 1, 'away': 1, 'introvert': 0, 'frame': 1, 'thing': 1, 'hate': 0, 'walk': 1}, 'go': 0, 'didnt': 0, 'wall': 0, 'poop': 1, 'back': 0, 'later': 0, 'love': 1, 'surpris': 0, 'head': 0, 'your': 0, 'seem': 1, 'extrovert': 1, 'mind': 0, 'zana': 0, 'better': 0, 'turn': 0, 'wann': 0, 'sometim': 0, 'away': 0, 'introvert': 1, 'frame': 0, 'thing: 0, 'mind': 0, 'tara': 0, 'thing: 0, 'thing: 0, 'mate': 0, 'thing': 0, 'mate': 0, 'man': 0, 'sometim': 0, 'man': 0, 'sometim': 0, 'man': 0, 'sometim': 0, 'mind': 0, 'man': 0, 'mind': 0, 'mind': 0, 'man': 0, 'man
```

Dibawah ini adalah vektor idf dari dokumen tes (atas) dan vektor tf-idf dari vektor tf query dan vektor idf dokumen tes (bawah). Untuk selanjutnya, setiap dokumen akan dihitung vektor tf-idf nya masing-masing agar dapat dihitung nilai similaritasnya dengan query.

```
('go': 2.09861228866811, 'didnt': 2.09861228866811, 'well': 2.09861228866811, 'poop': 1.1823215567939547, 'back': 2.09861228866811, 'later': 2.0986122886681
```

# 4.2.2 Percobaan Sort berdasar Cosine Similarity (query : Zara love to hate walk)

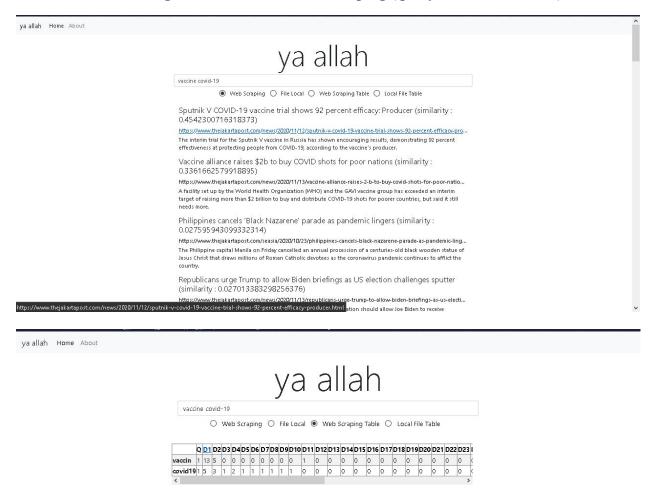
Menggunakan query yang sama seperti percobaan 4.2.1, didapat hasil:

```
0.08030843093423182
0.10657337100067675
0.0
0.7800676252548838
0.9457026152328998
[('link': 'test5.com', 'content': 'Zara love to hate walk', 'similarity': 0.9457026152328958}, {'link': 'test4.com', 'content': 'poop He hated that he loved what she hated about hate.', 'similarity': 0.7800676255548838}, ('link': 'test5.com', 'content': 'poop He hated that he loved what she hated about hate.', 'similarity': 0.7800676255548838}, ('link': 'test6.com', 'content': 'poop He was an introvert that extroverts seemed to love.', 'similarity': 0.106573371000676755, ('link': 'test1.com', 'content': 'poop Sometimes it is better to just walk offen the warning and go back to them later when you're in a better frame of mind.', 'similarity': 0.08030843093423182), ('link': 'test3.com', 'content': 'poop He didn't heed the warning and it had turned out surprisingly well.", 'similarity': 0.09)]
```

Dengan 5 baris teratas menyatakan nilai cosine similarity masing-masing dokumen (belum terurut sesuai similaritas) dan dibawahnya merupakan hasil sorting dictionary dokumen tes menurut similaritas dengan query

# 4.3 Implementasi pada Website

## 4.3.1 Percobaan dengan dokumen hasil web scraping (query: vaccine covid-19)



# 4.3.2 Percobaan dengan menggunakan dokumen unggahan (upload)

Akan diunggah 2 dokumen (test01.txt dan test04.txt), lalu dimasukkan query "Today rainbow shoes", sehingga didapat hasil :

# ya allah

Today rainbow shoes

○ Web Scraping ● File Local ○ Web Scraping Table ○ Local File Table

#### file2 (similarity: 0.29451291479781705)

#### /bd/toctO4 bd

She didn't understand how changed worked. When she looked at today compared to yesterday, there was nothing that she could see that was different. Yet, when she looked at today compared to last year.

### file1 (similarity: 0.10201729387804385)

#### /bxt/test01.bxt

The shoes had been there for as long as anyone could remember. In fact, it was difficult for anyone to come up with a date they had first appeared. It had seemed they'd always been there and yet they

137.0.0.1.500006.464.401.4

ya allah Home About

# ya allah

Today rainbow shoes

○ Web Scraping ○ File Local ○ Web Scraping Table ● Local File Table

	Q	<u>D1</u>	D2
shoe	1	0	2
rainbow	1	3	0
today	1	2	0

127.0.0.1:5000/txt/test04.txt

#### **BAB V**

## KESIMPULAN, SARAN, DAN REFLEKSI

## 5.1 Kesimpulan

Kami telah berhasil membuat sebuah program berbasis situs web yang dapat menyelesaikan berbagai permasalahan aljabar linier. Berdasarkan hasil percobaan yang telah dilakukan program dapat menerima search query dan mengurutkan dokumen berdasarkan similaritas dengan query, serta menampilkan tabel kemunculan term di query dan di tiap dokumen.

#### 5.2 Saran

Kami juga menyadari jika program yang dibuat masih memiliki banyak kekurangan dan jauh dari sempurna. Oleh karena itu, saran untuk pengembangan aplikasi ini kedepannya dapat dengan memperindah UI pada frontend sehingga lebih estetis, dan *hosting* aplikasi web sehingga memiliki domain pada Internet sehingga dapat lebih mudah diakses. Selain itu, algoritma *web-scraping* perlu dikembangkan lebih lanjut karena algoritma yang saat ini statis (jika ingin menambahkan referensi dokumen harus menambahkan sintaks secara manual alias tidak efisien).

#### 5.3 Refleksi

Dengan diberikannya tugas ini, kami dapat lebih lanjut menjelajahi dan mendalami materi-materi terkait vektor khususnya aplikasi dot product terhadap sistem temu balik informasi yang sudah maupun belum dipelajari serta mengeksplor dan membuat situs web dengan *framework* pemrograman yang terkesan 'baru' bagi kami, yaitu Flask serta juga meningkatkan kemampuan memprogram dan bekerja dalam tim.

# Referensi:

Anton, Howard. (2013). Elementary Linear Algebra 11th Edition. Prof. DikLee, Vector Space Retrieval Models, Univ. of Science and Tech, Hong Kong.

Salton, G.; Buckley, C. (1988). Term-weighting approaches in automatic text retrieval

Wu, H. C.; Luk, R.W.P.; Wong, K.F.; Kwok, K.L. (2008). Interpreting TF-IDF term weights as making relevance decisions